UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
ESCOLA DE ENGENHARIA
DEPARTAMENTO DE ENGENHARIA ELÉTRICA

ROGIEL JOSIAS SULZBACH

Método de classificação e comparação de build orders de StarCraft II

Porto Alegre

2016

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
ESCOLA DE ENGENHARIA
DEPARTAMENTO DE ENGENHARIA ELÉTRICA

ROGIEL JOSIAS SULZBACH

Método de classificação e comparação de build orders de StarCraft II

Projeto de Diplomação apresentado ao Departamento de Engenharia Elétrica da Escola de Engenharia da Universidade Federal do Rio Grande do Sul, como requisito parcial para Graduação em Engenharia Elétrica

Orientador: Prof. Dr. Altamiro Amadeu Susin

Porto Alegre
2016

ROGIEL JOSIAS SULZBACH

Método de classificação e comparação de build orders de StarCraft II

Projeto de Diplomação apresentado ao Departamento de Engenharia Elétrica da Escola de Engenharia da Universidade Federal do Rio Grande do Sul, como requisito parcial para Graduação em Engenharia Elétrica

---

Prof. Dr. Altamiro Amadeu Susin
Orientador - UFRGS

Prof. Dr. Ály Ferreira Flores Filho
Chefe do Departamento de Engenharia Elétrica (DELET) - UFRGS

Aprovado em ??? de dezembro de 2016.

BANCA EXAMINADORA

Prof. Dr. Luiz Fernando Ferreira
UFRGS

Prof. Dr. Marcelo Soares Lubaszewski
UFRGS

Prof. Dr. Tiago Roberto Balen
UFRGS

Resumo

RESUMO Este trabalhado consiste no desenvolvimento de um método de classificação e comparação de *build orders* de partidas de StarCraft II. O método de classificação utiliza um modelo probabilístico onde é calculado estatísticas do tempo de execução de várias ações de uma *build order* como forma de associar uma probabilidade à um *label* do classificador. O método foi capaz de classificar com taxa de acerto média de 85%. Um teste de ruído onde foi adicionadas lacunas nas informações das *build orders* para simular a aquisição incompleta de informações numa partida real, o classificador conseguiu trabalhar com aproximadamente 10% de ruído, a partir deste valor, a taxa de erro aumentou significantemente. A comparação foi feita utilizando dois critérios: taxa de vitória e taxa de sobrevivência até os 10 minutos. A taxa de vitória informa quais *build orders* tem maior probabilidade de vitória independente do tempo de jogo, a taxa de sobrevivência até os 10 minutos indica a probabilidade com a qual uma *build order* consegue extender o jogo até o marco de 10 minutos, sem a derrota ou vitória de algum jogador.

Palavras-chave: classificador probabilístico de *build orders*; comparação de *build orders*; comparação de estratégias

Abstract

ABSTRACT This work consists the development of a classification and comparison method for StarCraft II build orders. The classification method uses a probabilistic model where statistics on the execution time of several build order actions are calculated to be able to infer a associated probability to each classification label. The method was able to classify with a average success rate of 85%. A noise test was performed to simulate a real gameplay condition where actions were removed from the build orders to emulate the lack of certain information. The classifier was able to cope with up to 10% of noise, higher values increased the error rate significantly. The comparison was made using two criterium: win rate and survivability rate up to 10 minute mark. The win rate criteria indicates the probability which a *build order* is capable achieving the highest win rate independent from the game length, the survivability rate up to the 10 minute mark indicates the probability in which a build order is able to extend a game past the 10 minute mark without defeat or victory of a player.

Keywords: build order probabilistic classifier; build order comparison; strategy comparison

Lista de Figuras

Lista de Tabelas

Lista de Abreviaturas e Siglas

BO	*Build Order*
SC2	*StarCraft II*
PDF	*Probability Distribution Function*
CDF	*Cumulative Distribution Function*
RTS	*Real Time Strategy*

Sumário

1 Introdução

1.1 Sobre o StarCraft II

StarCraft II é um jogo de estratégia militar em tempo-real desenvolvido pela *Blizzard Entertainment* onde três facções (ou raças) disputam partidas *multiplayer* (online com múltiplos jogadores) em modalidade 1 contra 1. O objetivo do jogo consiste em conseguir destruir todas as estruturas do adversário que provém infraestrutura para a construção e manutenção do exército.

O jogo possui um sistema de economia, onde para que um jogador possa treinar ou desenvolver uma tecnologia, é necessário que primeiro sejam extraído recursos do ambiente virtual de jogo. O jogo também apresenta um sistema de "arvore tecnológica"onde há um encadeamento de pre-requisitos para o treinamento e construção de unidades de exército mais avançadas. É a existência desta arvore tecnológica que possibilita que seja possível inferir e prever uma determinada estratégia do jogador.

O modo mais comum de execução de uma estratégia é utilização de *build orders*. Uma *build order* é uma sequência de ações tomadas por um jogador no decorrer do jogo, que, quando executadas de forma correta, oferecem alguma vantagem estratégica para o jogador. Muitas build orders são padronizadas e otimizadas por jogadores profissionais durante o treino e são popularizadas em campeonatos mundiais.

Neste trabalho será desenvolvido e implementado um método de classificação para *build order* de partidas de jogadores profissionais de StarCraft II. Foi feita a escolha de utilizar partidas profissionais pois são jogadores com elevado conhecimento do jogo e reagem de forma ótima para várias situações inusitadas ou inesperadas, o que reduz a variabilidade das medidas extraídas dos arquivos de *replay* do jogo. Para a extração de dados foi utilizado um pacote de *replays* (arquivo binário que codifica todas as ações tomadas em um jogo) de competições profissionais de StarCraft II durante o ano de 2016.

Uma aplicação direta para o método proposto é o desenvolvimento de uma inteligência artificial que seja capaz de tomar decisões ao longo de um jogo de forma verossímil à um jogador humano, conforme proposto em (SYNNAEVE; BESSIERE, 2011a). Outras aplicações incluem a otimização de estratégias de logística de transporte ou cálculo de parâmetros de ajuste de algoritmos

1.2 O uso de aprendizado de máquina em jogos de estratégia em tempo real

O uso de aprendizado de máquina em jogos de estratégia em tempo real (RTS) pode ser dividido em vários problemas: táticas, estratégias e *micro management* conforme definido por (SYNNAEVE; BESSIERE, 2011b).

Táticas se refere ao posicionamento de unidades no mapa e é diretamente dependente da forma com a qual as unidades interagem entre si no jogo. Dessa forma, uma solução para este problema deve considerar o mapa e as interações entre as mecânicas de cada unidade.

Os problemas de estratégia se referem ao plano geral de jogo. A estratégia surge de uma expectativa para o desenvolver do jogo, por exemplo, supondo que um jogador deseja investir fortemente na sua economia para que consiga construir unidades tecnológicas de maior custo. A estratégia é a forma com a qual ele vai conseguir atingir este objetivo. Em geral, a estratégia é independente do mapa em que jogo está sendo jogado, mas é diretamente relacionado à raça do oponente, suas escolhas tecnológicas e sua gerência da economia (geralmente denominado de *macro management*). A estratégia de um jogador está diretamente relacionada com a sua escolha *build order*.

Por fim, os problemas de *micro management* consistem na gerência de unidades individuais, ou seja, o jogador faz o controle de cada unidade do exercito de forma individual. O *micro management* é uma especialização das táticas, mas se refere à cada unidade individual ao invés do exército inteiro.

2 Revisão Bibliográfica

2.1 Trabalhos anteriores

"A Data Mining Approach to Strategy Prediction"(WEBER; MATEAS, 2009) apresentaram uma forma de expressar uma *build order* de StarCraft Brood War em um vetor de *features* para processamento bem como a performance de quatro algoritmos de classificação. No trabalho concluíram que os diferentes algoritmos possuiam performance diferenciada nos diversos estágios de jogo. O modelo de codificação de features proposto baseava-se num critério de primeira-aparição, isto é, o vetor de *features* contém o instante em que a primeira instância de uma dada unidade ou estrutura ocorria no jogo e, caso não houvesse ocorrência, utilizava um valor padronizado de zero.

Adicionalmente, a fim de simular efeitos de *scouting* ruído foi adicionado nos vetores de *features* como forma de gerar variação nos *timings* de cada ação e então analisar a performance dos algoritmos. Foi concluído que todos os algoritmos perdiam precisão proporcional à quantidade de ruído adicionada, no entanto o algoritmo de k-NN (k-*nearest neighboors*) não degradou a performance de forma tão drástica quanto os outros algoritmos. Também foi adicionado outro teste de ruído para simular informação incompleta: lacunas foram inseridas no vetor de *features* a fim de emular a situação em que o jogador não consegue extrair uma informação do jogo do oponente. Com este tipo de ruído, a conclusão foi de que a precisão dos algoritmos de decaía de forma linear com o nível de ruído adicionado no vetor.

Em "A Bayesian Model for Opening Prediction in RTS Games with Application to StarCraft"(SYNNAEVE; BESSIERE, 2011a), baseado no trabalho anterior de (WEBER; MATEAS, 2009), realizaram o desenvolvimento de um modelo Bayesiano para classificação de build orders de StarCraft: Brood War utilizando um método de extração de *features* de ações significativas dos replays. A extração do replay considerava estruturas na arvore de tecnologia e considerava apenas a primeira construção de uma estrutura e o índide da sequencia de construção era utilizado para treinar o sistema. O método era capaz de identificar a abertura do jogador após a construção de, na média, 10 estruturas. Contudo, devido ao numero de limitado de *features*, era possível enumerar todas as possibilidades de jogos possíveis (em torno de 1000 por raça). O método era adequado para classificação em que a informação era limitada, por exemplo, era adequada para o contexto de uma inteligência artificial de toma suas decições baseada na sua capacidade de *scouting* (tentar descobrir a estratégia de um outro jogador utilizando uma unidade que descobre cada estrutura feita pelo oponente).

(SYNNAEVE; BESSIERE, 2011b) apresenta uma análise extensiva para técnicas e dificuldades encontradas ao aplicar algoritmos de aprendizado de máquina em diversos tipos de jogo, incluindo jogos de estratégia em tempo real (RTS).

2.2 A estrutura estatística de uma *build order*

Uma build order genérica pode ser expressa como uma sequência de ações cujo valor tempo de execução médio e desvio padrão estão relacionados com uma função distribuição de probabilidade.

Seja A uma ação arbitrária, A_n a sequência da ação durante o jogo (primeira vez que ela é executada, segunda, terceira, etc...), BO seja uma *build order* em que a sequência de ações A_n foram executadas e t o tempo de jogo em minutos. Dessa forma, podemos expressar a distribuição de probabilidade de uma sequência da forma indicada na Figura 1:

Figura 1 – Exemplo de uma distribuição de probabilidade de uma ação com 2 repetições

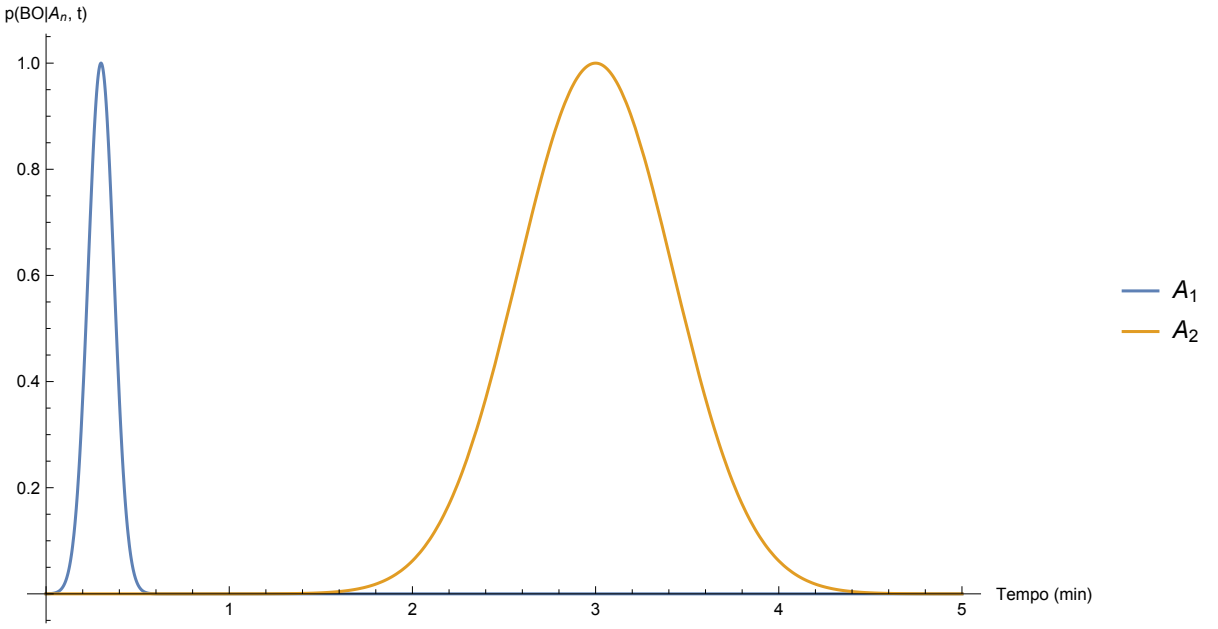

Na Figura 1 é possível observar que a primeira vez que a ação é executada, a tolerância para atraso é pequena, contudo, na segunda execução a tolerância de atraso é muito maior, pois o efeito da arvore tecnológica implica que uma ação atrasada irá atrasar as duas ações dependentes.

A tolerância de execução se faz necessária pois um jogador pode atrasar alguns segundos por múltiplos motivos durante o jogo, embora ele ainda esteja executando a mesma build-order.

Para uma *build order* real, haverá uma distribuição de probabilidade para cada uma das ações que podem oscilar em torno de 30 a 40 dependendo da facção do jogador.

2.3 Fator de *branching* de um jogo de StarCraft: BroodWar

Em teoria dos jogos, *branching factor* é o número de nós-filho em cada um dos nós de ações possíveis no jogo, isto é, é o número de opções que um jogador tem disponível em cada momento.

Infelizmente não há análises cientificas feitas para a complexidade de um jogo de StarCraft II, mas é possível realizar uma comparação utilizando o jogo antecessor da série, StarCraft: Brood War lançado em 1998. De acordo com (WEBER; MATEAS, 2009), StarCraft: BroodWar possui um fator de branching estimado médio de 1×10^6 que, comparado à um jogo de xadrez onde a média é de 35, é um valor extremamente alto. O alto nível de complexidade força que seja utilizado um modelo probabilístico ao invés de uma análise determinista, uma vez que é impossível obter, ou sequer gerar, uma amostra para todas as possibilidades de jogos. Devido a novas mecânicas de jogo introduzidas em StarCraft II espera-se a complexidade seja superior à de seu antecessor.

2.4 O Teorema de Bayes

O Teorema de Bayes relaciona a probabilidade de um evento associado à uma restrição. A definição matemática do teorema é dada pela Equação 2.1:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \tag{2.1}$$

onde A é um evento, B é a restrição do evento A. Dessa forma, é possível determinar a probabilidade do evento A ter acontecido, dado que o evento B foi observado.

Em termos da análise de *build orders*, pode-se aplicar o teorema conforme a Equação 2.2:

$$P(BO|A,t) = \frac{P(A|BO,t)P(BO)}{P(A,t)} \tag{2.2}$$

onde BO é uma *build order* qualquer que deseja-se estimar a probabilidade de estar sendo executada, dado que o jogador executou a ação A no tempo t. Para tanto, precisa-se determinar 3 fatores:

- $P(A,t)$: a probabilidade de um jogador executar a ação A no instante t, independe da *build order*;

- $P(BO)$: a probabilidade de um jogador executar a *build order* BO, independente da ação que o jogador está executando;
- $P(A|BO, t)$: a probabilidade de ter executado a ação A supondo que o jogador está executando a *build order* BO no instante t;

3 Métodologia

Neste trabalho foi utilizado Python 2.7 como a linguagem de programação para a implementação do método. Este motivo foi guiado principalmente pelo fato da biblioteca oficial de processamento de replays oferecida pela Blizzard Entertainment, Inc. (desenvolvedor do StarCraft II) ser em Python. A biblioteca de processamento de replays oficial, *s2protocol*(Blizzard Entertainment, Inc., 2013) é de código-fonte aberto e está disponível no GitHub. Demais códigos utilizados são parte de uma distribuição padrão do Python 2.7 ou foram desenvolvidos para o trabalho.

3.1 Extração dos dados

Os replays de StarCraft II são arquivos do tipo MoPAQ, um formato proprietário desenvolvido pela Blizzard Entertainment nos anos 90 para uso em seus jogos. Embora o formato seja proprietário é possível localizar na internet uma gama de implementações ou documentação desenvolvida por engenharia reversa. Um arquivo MPQ é análogo à um arquivo ZIP e contém um índice de arquivos e blocos de conteúdo. Nos *replays* há uma série de *stream* de eventos de jogo e neste trabalho somente será utilizado o stream chamado "Tracker Events"que são eventos cujo conteúdo é destinado para ferramentas que desejam processar os replays, ao contrário de informações úteis para a simulação do jogo. Este *stream* está armazenado como "replay.tracker.events"dentro do MPQ.

O *stream* de *Tracker Events* foi processado utilizando uma classe em Python que extrai as seguintes informações do evento:

- Nome (tipo) do evento;
- *Game loop* do evento (o número de iterações do loop principal do jogo);
- ID do jogador que gerou o evento;
- Estrutura de dados específica de cada evento;

A expressão de conversão de *game loops* para o tempo, em segundos é dada pela Equação 3.1.

$$t_{seg} = 16 \cdot n_{loops} \cdot \frac{26}{36} \cdot \frac{131}{148} \tag{3.1}$$

onde t_{seg} é o tempo em segundos, n_{loops} é o número de *game loops*.

Dentre os vários tipos de eventos contidos neste stream, 3 destes eventos são interessantes na análise:

NNet.Replay.Tracker.SUnitBornEvent evento disparado para cada unidade/estrutura criada no jogo. Este evento somente é despachado para unidades que aparecem no campo de batalha de forma "pronta"(Blizzard Entertainment, Inc., 2013), isto é, no momento em que a unidade pode ser vista pelo jogador, ela já pode ser controlada.

NNet.Replay.Tracker.SUnitInitEvent semelhante ao evento SUnitBornEvent, mas este evento é despachado para unidades que são construídas diretamente no campo de batalha e não estão disponíveis para jogo imediatamente no instante do evento(Blizzard Entertainment, Inc., 2013). Embora a unidade/estrutura neste evento não seja imediatamente utilizável, no método proposto, apenas o tempo em que usuário inicia a construção é considerado.

NNet.Replay.Tracker.SUpgradeEvent evento disparado para cada melhoramento de exército realizado pelo jogador. Estes eventos são muito importantes pois podem indicar ou refinar a intenção do jogador.

Apenas uma informação é extraída da estrutura de dados específica dos eventos: o nome da unidade, estrutura ou melhoramento feito pelo jogador. Este nome é único para cada tipo de unidade, estrutura ou melhoramento e cada um desses nomes são considerados como ações individuais que podem ser executadas pelo jogador. A única exceção é a exclusão de unidades do tipo trabalhadoras e estruturas que oferecem suprimento ao jogador. Estas unidades foram removidas porque num jogo regular estas ações ocorrem muitas vezes e há muita variância na execução delas, logo, incorrendo num prejuízo na qualidade do resultado final.

Uma vez que após os 6 minutos de jogo, a partida se torna reativa, ao invés de algorítmica, a sequência de eventos é truncada até os 6 minutos de jogo. Isto garante que as informações tenham menor variabilidade. Ao decorrer da partida, as ações executadas por um jogador começam a se tornar em resposta das ações do outro jogador e, portanto, não há sentido realizar uma classificação de *build order* para ações que ocorrem além de um certo limite de tempo.

3.2 *Dataset* de referência

Como não há nenhum índice de replays e build orders disponível publicamente o conjunto de replays utilizado para treinamento e validação foi classificado manualmente utilizando replays de diversos campeonatos do ano de 2016

Intel Extreme Masters 10 : 19 *replays*

Intel Extreme Masters 11 : 35 *replays*

WCS Spring Championship 2016 : 54 *replays*

totalizando 108 *replays*.

Para a classificação manual das estratégias cada replay foi assistido no jogo e classificado conforme as regras abaixo:

- A composição de exército de um jogador no instante do primeiro ataque realizado por ele;
- Se o jogador fosse atacado por outro e tivesse mais de 8 unidades perdidas, o *replay* era descartado;
- Caso não houvesse investida por parte dos dois jogadores até os 6 minutos de jogo, a composição de exército do jogador aos 6 minutos de jogo era classificada.

Um exército em StarCraft II pode ser composto por mais de 10 tipos de unidades diferentes, contudo isto é incomum. De forma geral, exércitos são compostos por um grande número de unidades básicas de ataque e algumas unidades de suporte. Na classificação, as unidades de suporte foram desprezadas na composição do exército. Esta regra é violada somente caso a unidade de suporte seja incomum ou trouxe um benefício significante para o jogador, como estratégias do tipo *rush* (criar um exército o mais rápido possível, geralmente em sacrifício da economia).

3.3 Treinamento

O treinamento foi realizado de forma simples: a sequência de ações para cada *replay* era iterada e o tempo de execução da ação era gravado em uma lista. Uma lista separada era usada para cada repetição. Por exemplo, supondo que as *build orders* BO_1 e BO_2 sejam duas amostras com o mesmo *label*:

Tabela 1 – Um exemplo de uma *build order* com as ações A_1 e A_2 ocorrendo nos tempos t_n.

BO_1		BO_2	
T	**A**	**T**	**A**
t_1	A_1	t_2	A_1
t_3	A_1	t_4	A_1
t_5	A_2	t_6	A_1
t_7	A_1	t_8	A_2

Na Tabela 1, observa-se nas últimas 2 linhas da tabela que há uma inversão de sequência de execução das ações. Esta alteração não implica que as *build order* sejam diferentes, é muito provável que os tempos t_5, t_6, t_7 e t_8 sejam muitos próximos e são independentes. Dessa forma, as duas listas terão o seguinte conteúdo:

$$\begin{aligned} T_{A_1} = \{&\{t_1, t_2\}, \\ &\{t_3, t_4\}, \\ &\{t_6, t_7\}\} \end{aligned} \tag{3.2}$$

onde T_{A_1} é o vetor de tempos da execução de cada repetição da ação A_1 nos múltiplos *replays* processados. $\{t_1, t_2\}$ representa os tempos da primeira repetição, $\{t_3, t_4\}$ da segunda e $\{t_6, t_7\}$ da terceira.

$$T_{A_2} = \{\{t_5, t_8\}\} \tag{3.3}$$

onde T_{A_2} é o vetor de tempos da execução de cada repetição da ação A_2 nos múltiplos *replays* processados. Esta ação possui uma única repetição.

Seja $\mu(T_x, R)$ a média do vetor de tempo T_x para a repetição R e $\sigma(T_x, R)$ o desvio padrão do vetor de tempo T_x para a repetição R, então a distribuição p de probabilidade de uma ação pode ser definida como:

$$p_{T_x}(t, R) = Ae^{-\frac{(t-\mu(T_x,R))^2}{\sigma(T_x,R)^2}} \tag{3.4}$$

onde A é a frequência com que um par ação-repetição ocorre dentre todas as amostras de treinamento utilizadas, μ é o tempo médio de execução do par ação-repetição e σ e o correspondente desvio-padrão.

A Equação 3.4 apresenta a função distribuição de probabilidade para uma ação. Isto é, representa a probabilidade de uma ação qualquer A pertencer a uma *build order* BO_1 dado que a ação foi executada pelo jogador no instante t.

Esta função é uma variação da função distribuição de probabilidade Gaussiana, no entanto, é ajustada de forma que, para o ponto médio, seu valor seja unitário (para $A = 1$) ou tenha o valor de A, que indica a frequência com que uma ação ocorreu nos *datasets* de treinamento.

Para o cálculo da média (μ) e desvio padrão (σ) os itens internos do vetor T_x são utilizados. Para o exemplo apresentado nas Equações 3.2 e 3.3, as médias são dadas pelos vetores das Equações 3.5 e 3.6, respectivamente:

$$\mu_{A_1} = \left\{\frac{t_1 + t_2}{2}, \frac{t_3 + t_4}{2}, \frac{t_6 + t_7}{2}\right\} \tag{3.5}$$

$$\mu_{A_1} = \left\{ \frac{t_5 + t_8}{2} \right\} \tag{3.6}$$

O cálculo de desvio padrão para os vetores das Equações 3.2 e 3.3 foi omitido no exemplo pois a expressão é complexa e não influencia no entendimento e um valor genérico é apresentado nas Equações 3.7 e 3.8.

$$\sigma_{A_1} = \{\sigma_{A_1,1}, \sigma_{A_1,2}, \sigma_{A_1,3}\} \tag{3.7}$$

$$\sigma_{A_1} = \{\sigma_{A_2,1}\} \tag{3.8}$$

Neste exemplo, de forma a simplificar o cálculo, assume-se que a frequência de cada par ação-repetição é unitária.

É possível substituir os valores de média e desvio-padrão das Equações 3.5, 3.6, 3.7 e 3.8 na função distribuição de probabilidade da Equação 3.4. O vetor final é denominado de "vetor de probabilidades".

Com os resultados de média (Equações 3.5 e 3.6) e desvio padrão (Equações 3.7 e 3.8), é possível obter um gráfico do formato da distribuição de probabilidade conforme representado nas Figuras 2 e 3.

Figura 2 – Exemplo da distribuição de probabilidade da ação A_1.

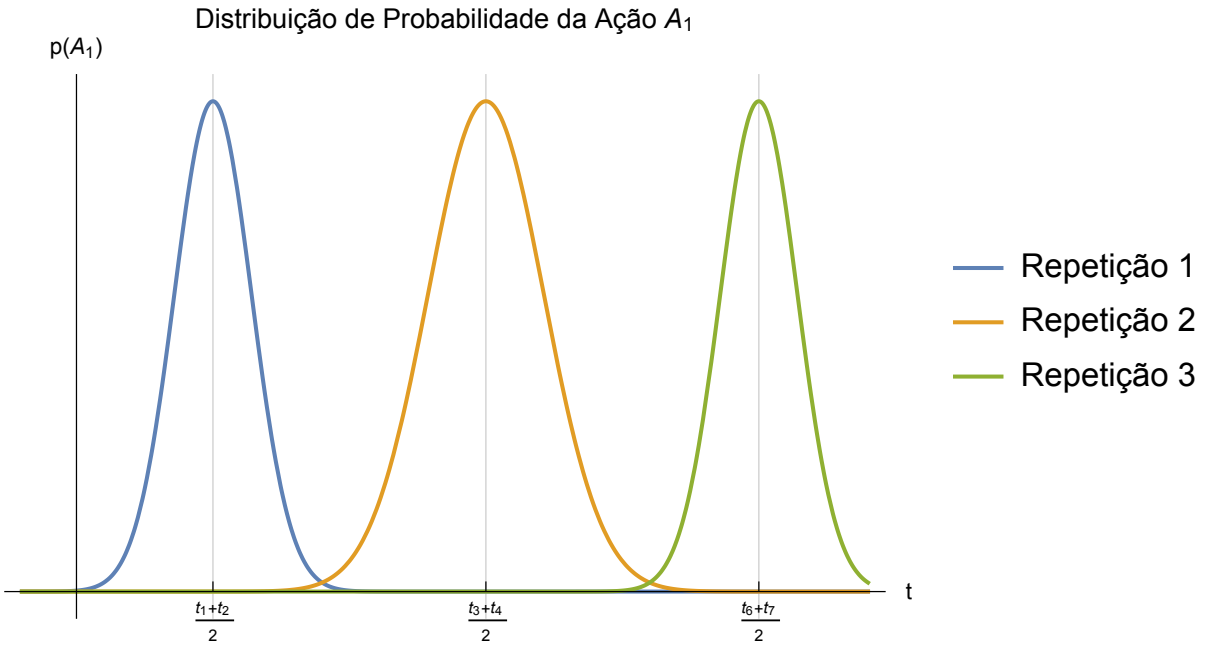

Na Figura 2, a curva em azul representa a primeira repetição da ação (nos tempos t_1 e t_2), a curva em laranja representa a segunda repetição (nos tempos t_3 e t_4) e a curva em verde representa a terceira repetição da ação (tempos t_6 e t_7).

Figura 3 – Exemplo da distribuição de probabilidade da ação A_1.

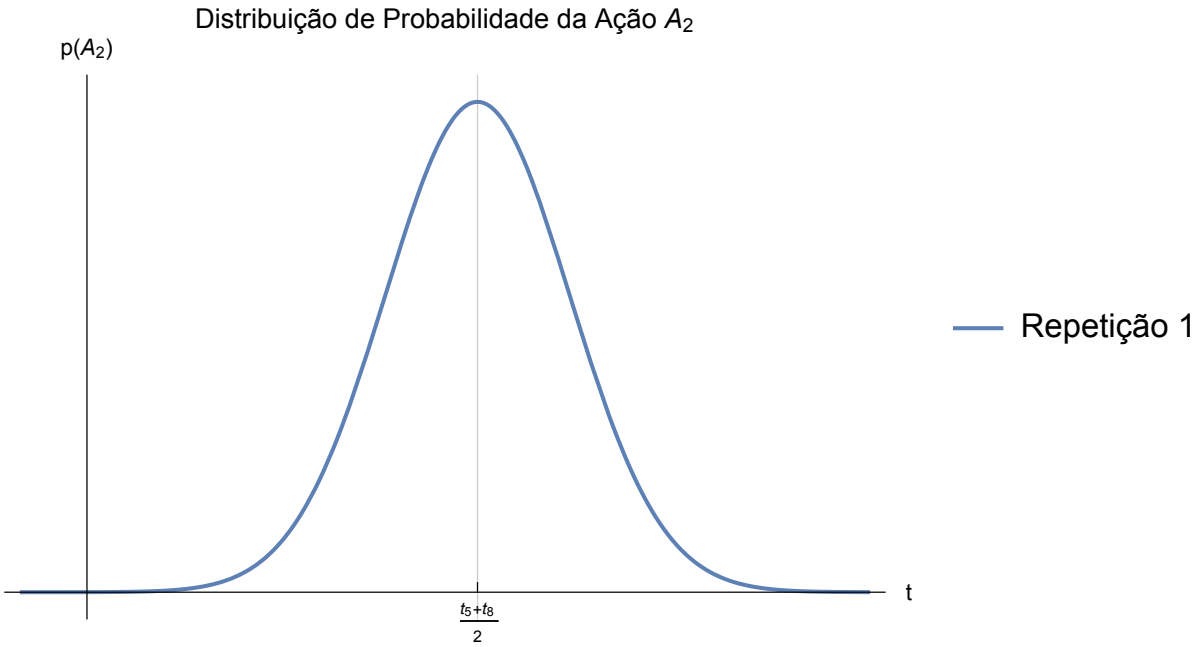

Na Figura 3 a ação A_2 somente é executada uma única vez no exemplo, então apenas uma repetição é mostrada no gráfico. A ação corresponde aos instantes de tempo t_5 e t_8.

3.3.1 Forma Matricial

O treinamento pode ser realizado de forma matricial. Onde as colunas indicam as ações e as linhas indicam as repetições de cada ação respectiva. Dessa forma, é possível definir uma matriz de médias e desvios padrões.

Dado um conjunto de N ações que podem se repetir até M vezes, então, é possível definir uma matriz $M \times N$, cujos elementos são formatos pelo tempo médio de execução de cada par ação-repetição, denominada de "matriz de média do tempo de execução", expressa na Equação 3.9.

$$\mu = \begin{pmatrix} \mu_{A_1,1} & \mu_{A_2,1} & \cdots & \mu_{A_N,1} \\ \mu_{A_1,2} & \mu_{A_2,2} & \cdots & \mu_{A_N,2} \\ \vdots & \vdots & \ddots & \vdots \\ \mu_{A_1,M} & \mu_{A_2,M} & \cdots & \mu_{A_N,M} \end{pmatrix} \tag{3.9}$$

De forma análoga a matriz de média do tempo de execução, é possível definir a "matriz de desvio padrão do tempo de execução"para os valores de desvio padrão do tempo de execução de cada par ação-repetição e a outra matriz denominada "matriz de frequência de ocorrência de repetição"que define a frequência de ocorrência de um dado par ação-repetição no conjunto de amostras observadas. A definição formal da matriz de desvio padrão do tempo de execução está apresentada na Equação 3.10. A definição formal da matriz de frequência de repetição está apresentada na Equação 3.11.

$$\sigma = \begin{pmatrix} \sigma_{A_1,1} & \sigma_{A_2,1} & \cdots & \sigma_{A_N,1} \\ \sigma_{A_1,2} & \sigma_{A_2,2} & \cdots & \sigma_{A_N,2} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{A_1,M} & \sigma_{A_2,M} & \cdots & \sigma_{A_N,M} \end{pmatrix} \tag{3.10}$$

$$F = \begin{pmatrix} F_{A_1,1} & F_{A_2,1} & \cdots & F_{A_N,1} \\ F_{A_1,2} & F_{A_2,2} & \cdots & F_{A_N,2} \\ \vdots & \vdots & \ddots & \vdots \\ F_{A_1,M} & F_{A_2,M} & \cdots & F_{A_N,M} \end{pmatrix} \tag{3.11}$$

Substituindo-se as matrizes de média e desvio padrão do tempo de execução e de frequência de ocorrência de repetição, Equações 3.9, 3.10 e 3.11, respectivamente, na função de distribuição de probabilidade dada pela Equação 3.4, é possível construir uma matriz de probabilidade. Todas as operações entre matrizes são realizadas utilizando operadores de Hadamard (HORN, 1990) ou operações termo-a-termo.

Por convenção matemática, e para evitar um problema de indeterminação no cálculo de probabilidade associada, uma ação cuja repetição não ocorre nas amostras encontradas, deve ter o valor de média não-nulo e o valor de desvio padrão deve ser infinito. Por convenção, neste trabalho utiliza-se o valor de média 0.0. Esta escolha foi feita para que a função distribuição de probabilidade seja avaliada com valor 1.0 para ações inexistentes na amostra de treinamento, independente da ação ser executada pelo jogador numa *build order* utilizada no processo de classificação.

$$p(t) = \begin{pmatrix} F_{A_1,1} e^{-\frac{(t_{A_1,1}-\mu_{A_1,1})^2}{{\sigma_{A_1,1}}^2}} & F_{A_2,1} e^{-\frac{(t_{A_2,1}-\mu_{A_2,1})^2}{{\sigma_{A_2,1}}^2}} & \cdots & F_{A_N,1} e^{-\frac{(t_{A_N,1}-\mu_{A_N,1})^2}{{\sigma_{A_N,1}}^2}} \\ F_{A_1,2} e^{-\frac{(t_{A_1,2}-\mu_{A_1,2})^2}{{\sigma_{A_1,2}}^2}} & F_{A_2,2} e^{-\frac{(t_{A_2,2}-\mu_{A_2,2})^2}{{\sigma_{A_2,2}}^2}} & \cdots & F_{A_N,2} e^{-\frac{(t_{A_N,2}-\mu_{A_N,2})^2}{{\sigma_{A_N,2}}^2}} \\ \vdots & \vdots & \ddots & \vdots \\ F_{A_1,M} e^{-\frac{(t_{A_1,M}-\mu_{A_1,M})^2}{{\sigma_{A_1,M}}^2}} & F_{A_2,M} e^{-\frac{(t_{A_2,M}-\mu_{A_2,M})^2}{{\sigma_{A_2,M}}^2}} & \cdots & F_{A_N,M} e^{-\frac{(t_{A_N,M}-\mu_{A_N,M})^2}{{\sigma_{A_N,M}}^2}} \end{pmatrix} \tag{3.12}$$

onde t é uma matriz que indica o tempo de execução dos pares ação-repetição de uma *build order* que se deseja classificar.

3.4 Classificação

O processo de classificação é realizado de forma independente para cada *label* (*build order*) utilizado no processo de treinamento. Os valores de probabilidade para cada par de ação-tempo de um *replay* são multiplicados e o valor final determina a semelhança de uma *build order* treinada e a executada.

Considerando-se o exemplo anterior, é possível aplicar o instante de execução de cada ação do jogador no vetor de ações correspondente e obter a probabilidade de que uma ação qualquer A. Dessa forma, a probabilidade total de que um conjunto de ações seja parte de uma *build order* qualquer é dada pela Equação 3.13:

$$p_{BO} = \prod_{n,i} p(BO|A_{(n,i)}, t) \tag{3.13}$$

onde n indica o tipo da ação, i a sua repetição e $p(BO|A_{(n,i)}, t)$ é a probabilidade de que a ação seja parte de uma build order BO dado que $A_{(n,i)}$ foi executada no instante de tempo t, conforme a Equação 3.4.

3.4.1 Forma Matricial

Dada a matriz de probabilidades de uma *build order* treinada, conforme a Equação 3.12, a probabilidade final de uma *build order* treinada é dada pela redução da matriz através da operação de multiplicação de seus termos, conforme Equação 3.14.

$$p_{BO} = \prod_{i,j} p(t)_{ij} \tag{3.14}$$

onde i e j são respectivamente as linhas e as colunas das matrizes de probabilidade e de tempo de execução da *build order* a ser classificada, t é a matriz de tempo de execução da *build order* para ser classificada, p é a matriz de probabilidades de uma *build order* qualquer BO e p_{BO} é a probabilidade reduzida da matriz p cujo valor é equivalente à operação da Equação 3.13.

3.5 Comparação

Para realizar a comparação das *build orders* foi adotado duas métricas distintas: taxa de vitória e taxa de sobrevivência após os 10 minutos de jogo. As duas métricas foram adotadas pois oferecem duas opções bastante interessantes. Pode-se optar por observar o quão provável é a vitória *build order* contra outra ou utilizar o dado para tomar uma decisão de qual *build order* maximiza a chance de vitória em um cenário.

Devido a forma de resposta do método, mesmo que uma *build order* seja muito diferente das conhecidas, o seu valor final de probabilidade não será 0. Devido à isso, utilizando o *dataset* de validação, é calculado um limite de decisão. Um valor, cujos resultados inferiores serão rejeitados na classificação. A métrica se faz necessária pois não foram adicionadas amostras para todas as *build orders* disponíveis já que existem inúmeras *build orders* e novas são inventadas a todo momento. O *threshold* é definido pelo menor valor de probabilidade retornado pelo processo de classificação.

A comparação foi feita utilizando todos os *replays* disponíveis no *dataset* de treinamento e de validação onde apenas partidas da raça Protoss versus Protoss foram utilizadas já que apenas *build orders* para a raça Protoss foram classificadas.

Cada arquivo de *replay* foi processado e a *build order* de cada jogador foi classificada, se o threshold de seleção foi respeitado para a *build order* de ambos jogadores. Supondo que o primeiro jogador tenha executado uma *build order* BO_1 e o segundo BO_2. Dessa forma, foi criado dois pares (BO_1, BO_2) e (BO_2, BO_1) onde contadores de vitória e de sobrevivência foram incrementados. No primeiro par, (BO_1, BO_2), é calculada a taxa de vitória e sobrevivência de BO_1 contra BO_2, isto é, a frequência com que BO_1 vence BO_2. No par (BO_2, BO_1) é calculada a frequência com que BO_2 vence BO_1.

Uma sobrevivência é considerada quando há algum evento do jogador após o marco de 10 minutos de jogo, garantindo que não houve derrota até aquele instante. A sobrevivência independe da vitória, um jogador pode sobreviver até os 11 minutos e perder uma partida. Uma vitória é calculada utilizando informações no cabeçalho do arquivo de *replay* que identifica jogadores vitoriosos e derrotados.

3.6 Implementação

A implementação do método foi feita em Python 2.7 utilizando a biblioteca s2protocol (Blizzard Entertainment, Inc., 2013) para processamento dos arquivos de *replay*, disponibilizada em licença de código fonte aberto no GitHub.

Para realizar a extração dos eventos do uma função chamada *parse()* foi definida. Esta função é responsável por extrair todas as *build orders* de todos jogadores que participaram na partida contida num arquivo de *replay*. A função pode ser dividida em 3 etapas.

Na primeira etapa, extrai-se do cabeçalho do arquivo informações que associam um identificador inteiro, denominado de *player ID* com o nome do jogador e a raça. O identificador inteiro é usado nas estruturas de dados dos eventos para associar o evento com um jogador. A Figura 4 apresenta o fluxograma do processamento do cabeçalho do

arquivo de *replay*. Com estes dados, é construído um dicionário contendo as seguintes informações.

```
players = {
    playerID: {
        'Name':       ..., // nome do jogador
        'BuildOrder': ..., // estrutura que lista as ações da build order
        'Race':       ...  // nome da raça do jogador
    }
}
```

Figura 4 – Fluxograma do processamento do cabeçalho do arquivo de *replay*

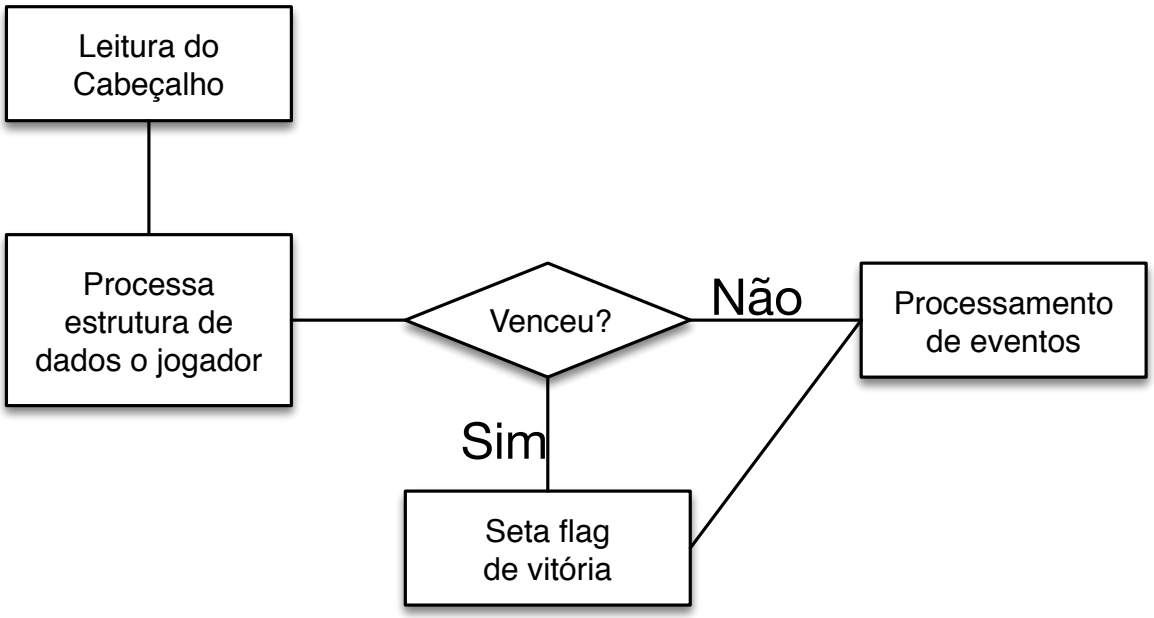

Depois de criada a estrutura de dados do jogador, é possível realizar a extração de cada evento do *replay*. A Figura 5 apresenta o fluxograma do processamento dos eventos do arquivo de *replay*. Para cada estrutura de dados de evento recebida pela biblioteca de processamento conforme o exemplo abaixo:

```
{'_bits': 296,
 '_event': 'NNet.Replay.Tracker.SUnitBornEvent',
 '_eventid': 1,
 '_gameloop': 2467,
 'm_controlPlayerId': 2,
 'm_unitTagIndex': 261,
 'm_unitTagRecycle': 1,
 'm_unitTypeName': 'Adept',
```

```
'm_upkeepPlayerId': 2,
'm_x': 34,
'm_y': 152}
```

Figura 5 – Fluxograma do processamento de eventos do arquivo de *replay*

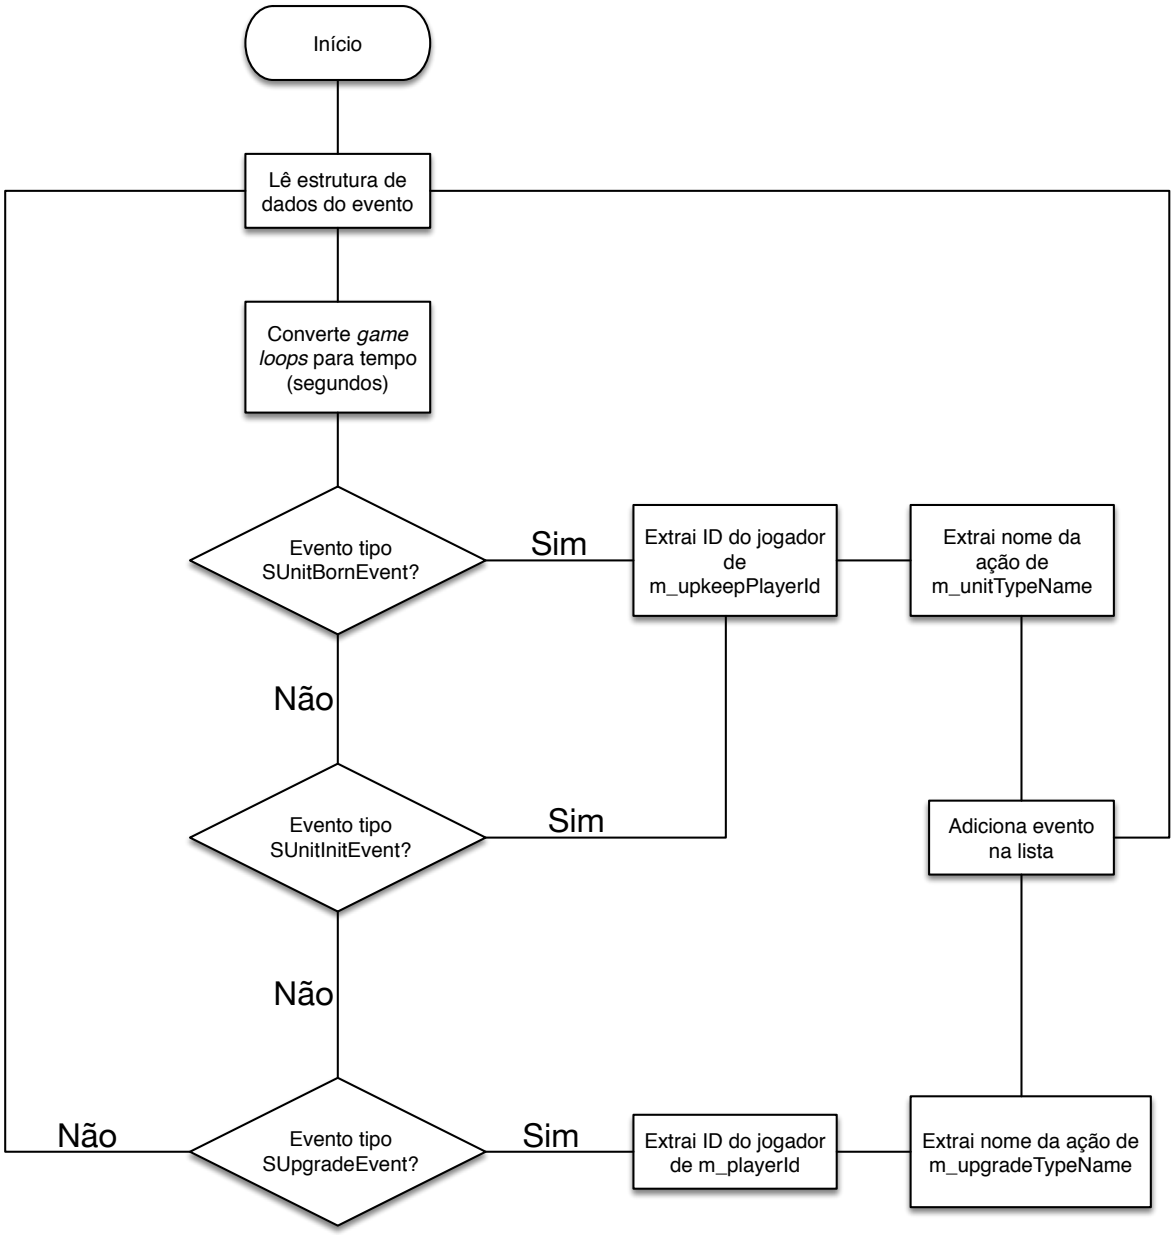

Antes de processar qualquer elemento do evento, converte-se o campo _gameloop que representa o número de loops de jogo transcorridos até o momento do evento. A conversão para tempo em segundos é feita utilizando a expressão da Equação 3.1. Se o tempo de execução é superior à 6 minutos, o evento é descartado.

Caso o tempo seja inferior ou igual à 6 minutos, checa-se o tipo de evento. Se o evento for do tipo **SUnitBornEvent**, **SUnitInitEvent** ou **SUpgradeEvent** extrai-se alguns atributos da sua estrutura de evento. Caso contrário, o evento é descartado.

Se o evento for do tipo **SUnitBornEvent** ou **SUnitInitEvent**, então extrai-se do campo m_unitTypeName o nome da unidade treinada e a ID do jogador que executou a ação, contida em m_upkeepPlayerId. A ID é usada para obter a estrutura de build order apresentada anteriormente e uma ação com nome m_unitTypeName e tempo de execução correspondente à _gameloop é adicionada na estrutura de dados de build order do jogador.

Se o evento for do tipo **SUpgradeEvent**, então extrai-se do campo m_upgradeTypeName o nome do melhoramento executado e a ID do jogador que executou a ação, contida em m_playerId. A ID é usada para obter a estrutura de build order apresentada anteriormente e uma ação com nome m_upgradeTypeName e tempo de execução correspondente à _gameloop é adicionada na estrutura de dados de build order do jogador.

Nem todos valores de m_unitTypeName ou m_upgradeTypeName são válidos e é necessário checar em uma lista de valores permitidos antes que os valores sejam adicionados à estrutura de dados de build order do jogador. A lista de todas ações permitidas estão no Anexo A.

É importante observar que não há sobreposição entre os nomes de unidades treinadas em m_unitTypeName e os nomes dos melhoramentos feitos em m_upgradeTypeName e portanto os próprios nomes são utilizados como ações. Isto é, conforme o exemplo dado, a sua ação correspondente no processo de treinamento do método é chamada de Adept pois é o valor contido no campo m_unitTypeName.

Após a construção da estrutura de dados de uma *build order*, é possível executar o algoritmo de treinamento. Este algoritmo é responsável pelo cálculo de média e desvio padrão de cada ação coletada na etapa anterior. O cálculo é feito conforme descrito na seção 3.3. A Figura 6 apresenta o fluxograma do processo de treinamento.

O classificador foi implementado numa classe em Python chamada de *BuildOrder-Matcher*. Esta classe é responsável pela organização das estruturas de dados do treinamento e classificação das *build orders*.

O processo de treinamento foi implementado num método denominado *train()* na classe *BuildOrderMatcher* onde é dado um conjunto de estruturas de *build order*, conforme extraído pelo método descrito na função *parse()*, e um *label* que identifica o nome que representa o conjunto de *build orders* dado. A função de treino itera sobre cada uma das *build orders* dadas e acumula o tempo de execução de cada uma das ações em termos das suas repetições em uma lista. A repetição é definida como a sequência em que uma mesma ação é executada. Se uma ação é executada ao total 3 vezes numa *build order*, então a primeira vez que ela é executada é definida como a repetição 1, a segunda vez que ela é

Figura 6 – Fluxograma do processo de treino

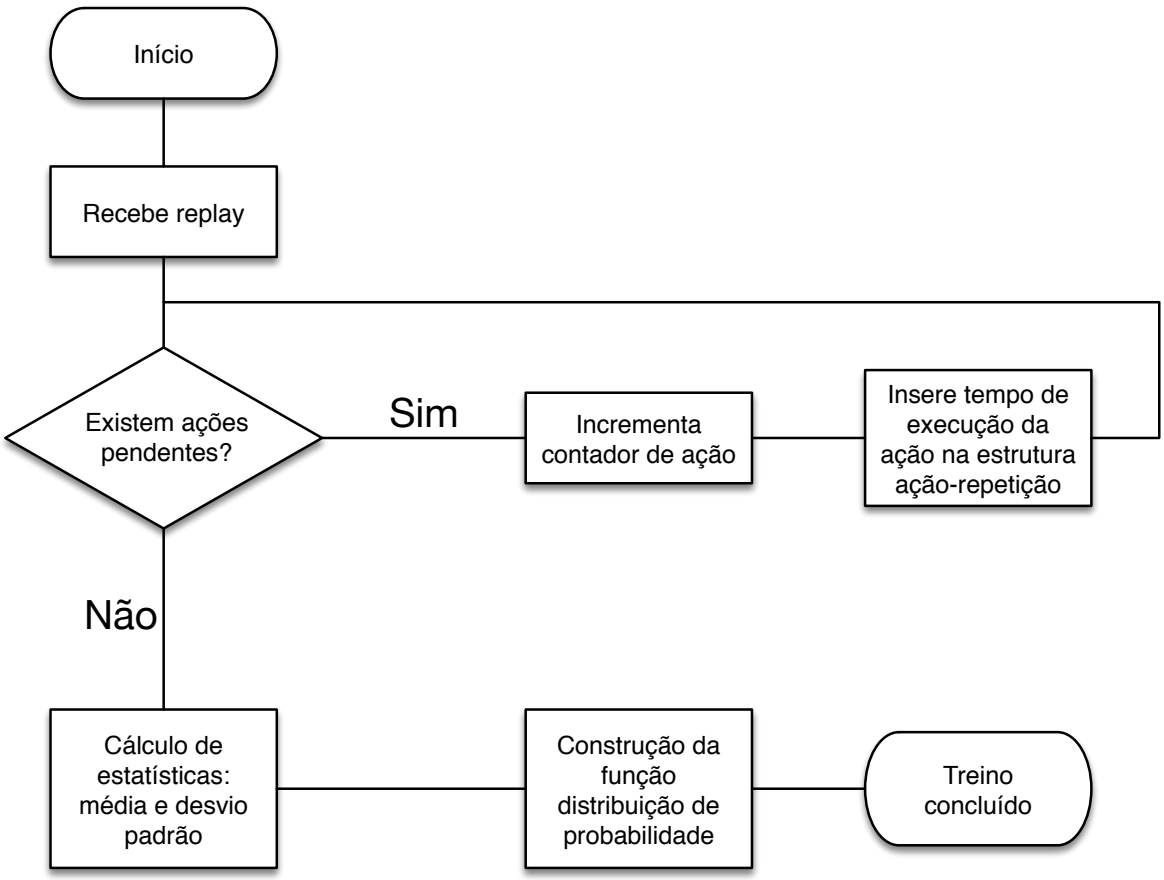

executada é definida como a repetição 2 e a terceira como a repetição 3. Os valores de tempo de cada par ação-repetição são adicionados em uma estrutura de dicionário com 3 níveis. O primeiro nível representa o *label* de treinamento, o segundo nível representa o nome a ação e o terceiro nível representa a repetição.

Após a adição de todas *build orders* e seus *labels* pelo método *train()* da classe *BuildOrderMatcher*, um segundo método *build_distribution()* deve ser invocado para que sejam geradas as funções distribuição de probabilidade conforme a Equação 3.4. Esta função é responsável pelo cálculo dos parâmetros da função distribuição de probabilidade. Um conjunto distinta de atributos da função distribuição de probabilidade é calculado e associado a cada par ação-repetição para cada *label* dado no método *train()*.

A função *build_distribution()* itera por repetição de cada ação de cada um dos labels dados em *train()* e verifica que o par ação-repetição ocorre em pelo menos 2 amostras, caso contrário não seria possível atribuir um valor de desvio padrão para o par. Se há ao menos 2 elementos, calcula-se o parâmetro A da Equação 3.4 pelo tamanho de elementos (valores de tempo em segundos em que cada amostra executou uma ação, se uma ação não foi executada em alguma amostra, a lista possui um item a menos). O parâmetro é calculado

dividindo-se o número de elementos de tempo na lista do par ação-repetição pelo número total de *build orders* dada para treinamento. De forma que, se um par ação-repetição ocorre em todas as amostras, seu valor é de 1.0 ou se um par ação-repetição ocorre em apenas duas de dez amostras de treinamento, seu valor é de 0.2.

Por fim, calcula-se o valor de média e desvio padrão do tempo de execução de cada par e constrói-se um objeto que representa de forma abstraída a função distribuição de probabilidade utilizando os parâmetros A, μ e σ. Ao invocar o método *apply()* com um valor de tempo t, é retornado o valor correspondente da função distribuição de probabilidade.

```
class NormalDistributionFunction:
    def __init__(self, mean, sigma=1.0, amplitude=1.0):
        self.mean = mean
        self.sigma = sigma
        self.amplitude = amplitude

    def apply(self, t):
        if t is None:
            return 0.0
        return self.amplitude * math.exp(-(math.pow(t-self.mean, 2) /
            (2 * math.pow(self.sigma, 2))))
```

O objeto representando a função distribuição de probabilidade é adicionado à uma estrutura de dicionário com 3 níveis. O primeiro nível representa o *label* de treinamento, o segundo nível representa o nome a ação e o terceiro nível representa a repetição.

Após a chamada do método *build_distribution()* a classe está pronta para classificação de outras *build orders* desconhecidas através do método *classify()* onde é dado a estrutura de dados de uma *build order* desconhecida e o algoritmo calcula os valores de probabilidade associada à cada *label*. O cálculo é feito conforme descrito na seção 3.4.

O método *classify()* itera nos *labels* de treinamento e itera sobre a sequência de ações executadas na *build order* dada. Um contador é mantido por *label* e por ação que indexa o índice de repetição que é incrementado a cada ocorrência de uma ação com mesmo nome. Com isto, dado o *label* da iteração, a ação ta iteração e o índice da repetição da ação, pode-se utilizar a função distribuição de probabilidade e calcular o valor de probabilidade associado ao par ação-repetição. O valor invidual de probabilidade de cada par é multiplicado pelo valor total de probabilidade do *label*. A função retorna um dicionário indexado pelo *label* e cujo valor é produto das probabilidades. A Figura 7 apresenta o fluxograma do processo de classificação.

A seleção da *build order* correta é feita escolhendo o label que possui o maior valor de probabilidade agregada.

Figura 7 – Fluxograma do processo de classificação

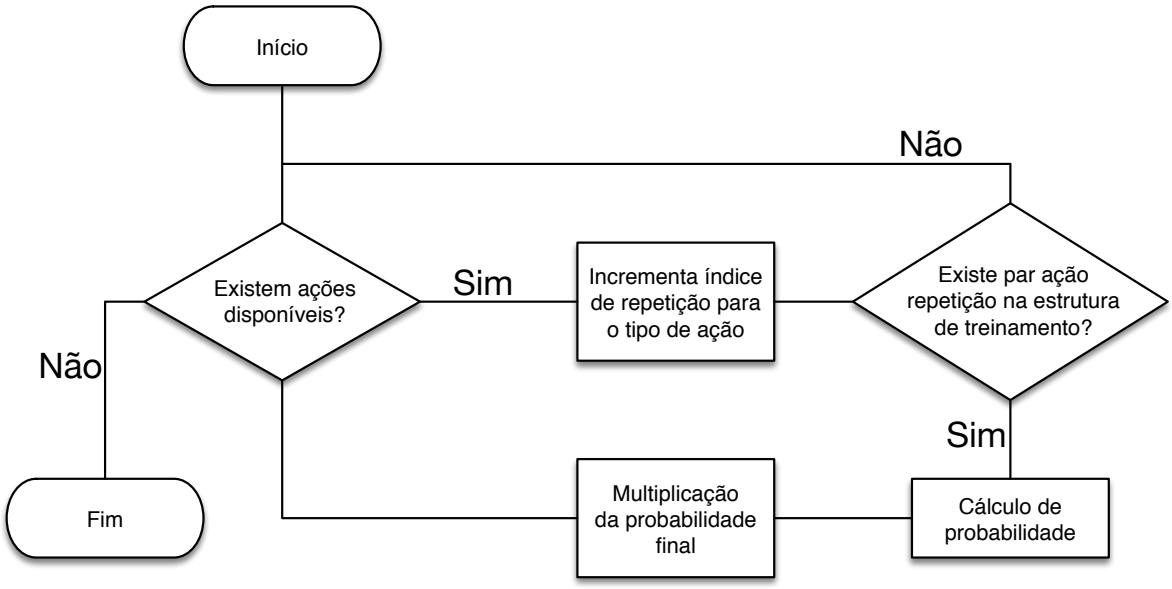

O código fonte da implementação e os arquivos de *replay* utilizados para treinamento, validação e comparação estão disponíveis em <https://github.com/Rogiel/ufrgs-projeto-diplomacao>.

3.6.1 Ações ignoradas

Conforme a lista de ações consideradas válidas pelo algoritmo do método no Anexo A, praticamente todas as unidades, estruturas e melhoramentos foram utilizados na classificação. De fato, foram excluídos apenas 2 itens do total: trabalhadores e estruturas de suprimento.

Esta decisão foi feita pois estes itens são fundamentais em todas as *build orders* e não adicionariam informações ao cálculo. Em especial, trabalhadores possuem uma característica importante.

Trabalhadores são sujeitos à tática executada pelo oponente chamada de *trabalhador*. O *trabalhador* consiste em impedir que um jogador ganhe recursos por um determinado tempo matando os trabalhadores ou fazendo com que o jogador os coloque num local seguro, para evitar que os mesmos sejam perdidos, onde não podem extrair recursos. Uma vez que os trabalhadores são perdidos o jogador é forçado à reconstrui-los sob penalidade de ficar atrasado em aspectos econômicos e portanto, novas ações de construção de trabalhadores são adicionadas à partida. A Tabela 2 exemplifica o problema de forma gráfica.

Tabela 2 – Resultado da validação cruzada

Esperado	Repetição	Ocorrido	Repetição
Trabalhador 1	1	Trabalhador 1	1
Trabalhador 2	2	Trabalhador 2	2
-		Trabalhador 1 morre	
-		Reconstruir trabalhador 1	3
Trabalhador 3	3	Trabalhador 3	4

Conforme mostrado na Tabela 2, após a perda do trabalhador 1, o jogador opta por reconstruí-lo que pelo processo de criação dos pares ação-repetição, a reconstrução seria considerada como sendo uma ação de construção do trabalhador 3, pois este seria o terceiro trabalhador a ser construído pelo jogador e o trabalhador 3 seria considerado como a repetição 4. Com a adição da ação "Reconstruir Trabalhador 1"as sequências das ações ficam fora de ordem que implica no aumento do desvio padrão de cada ação posterior de forma significativa (a ação de reconstruir introduz um *offset* na contagem das repetições), o que implicaria no aumento da taxa de erro de classificação. Para contornar o problema, trabalhadores foram excluídos da lista de ações utilizadas.

Estruturas de suprimento também foram excluídas porque a partir da terceira ou quarta repetição a variabilidade começa a crescer de forma significativa pois o instante de construção destas estruturas não depende do tempo de jogo e sim to total de suprimento suprimento disponível para o jogador. Uma estruturas de suprimento é construída quando o suprimento utilizado pelo jogador chega próximo do valor de suprimento total disponível.

4 Resultados e Discussões

No processo de treinamento, é extraído a sequência de construção de cada jogador (a *build order*), calculadas estatísticas de primeira ordem (média e desvio padrão) e a frequência de cada par ação-repetição em relação ao conjunto de replays correspondentes a mesma *build order*.

No processo de classificação, as probabilidades individuais de cada ação executada são calculadas e multiplicadas para obter um número que indica a probabilidade de que uma dado conjunto de ações pertença à uma *build order* conhecida.

O método foi treinado utilizando 7 build order da raça Protoss.

Adept Glaives : 6 replays

Adept Stargate : 14 replays

Adept Immortal : 13 replays

Stalker Immortal : 3 replays

Adept Prism DT : 5 replays

Stalker Disruptor : 5 replays

Blink Stalker : 8 replays

A Figura 8 apresenta um exemplo das funções distribuição de probabilidade para uma ação do tipo "Gateway"da *build order* "Adept Immortal".

Observa-se que a frequência de ocorrência das repetições no *dataset* de treinamento é decrescente. Isto é uma consequência do método escolhido para classificação. A primeira execução de uma ação, irá, independentemente do tempo em que for executada, considerada como a primeira repetição. A redução da frequência tem duas causas principais:

Alteração da estratégia do jogador : um jogador pode ter escolhido uma estratégia levemente diferente devido ao contexto do jogo ou em resposta à *build order* do oponente;

Ações opcionais : algumas ações podem ser opcionais e somente são executadas em alguns mapas.

Figura 8 – Forma gráfica de distribuição estatística de uma ação *Gateway* e suas repetições

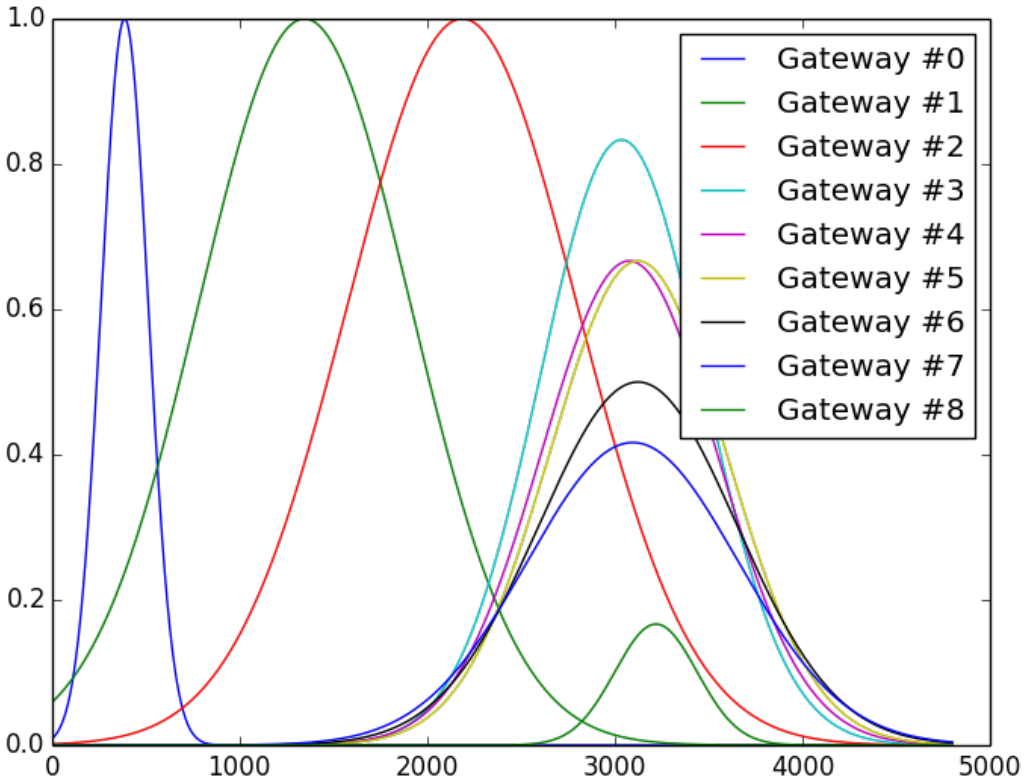

Há uma tendência no desvio-padrão e variância do tempo de execução do par ação-repetição de crescerem ao decorrer da partida. Os principais motivos deste crescimento é a incapacidade de jogadores humanos executarem as ações de forma perfeita e sem qualquer variabilidade. Este fator é agravado com a característica da "arvore tecnológica"onde algumas ações possuem dependências tecnológicas em outras anteriores. Embora a tendência seja visível na maior parte das ações, ainda é possível que ela reduza em alguns casos específicos.

Um exemplo onde o desvio padrão reduz de forma significante é visível na Figura 9, a primeira repetição possui um desvio padrão significantemente maior ao da segunda repetição. Este comportamento é esperado quando a primeira ação é considerada opcional e incorre num erro onde a primeira repetição deveria ter frequência menor que a segunda. Infelizmente, devido à forma de como o método de separação foi estabelecido, não é possível evitar este efeito.

Figura 9 – Forma gráfica de distribuição estatística de uma ação *Immortal* e suas repetições

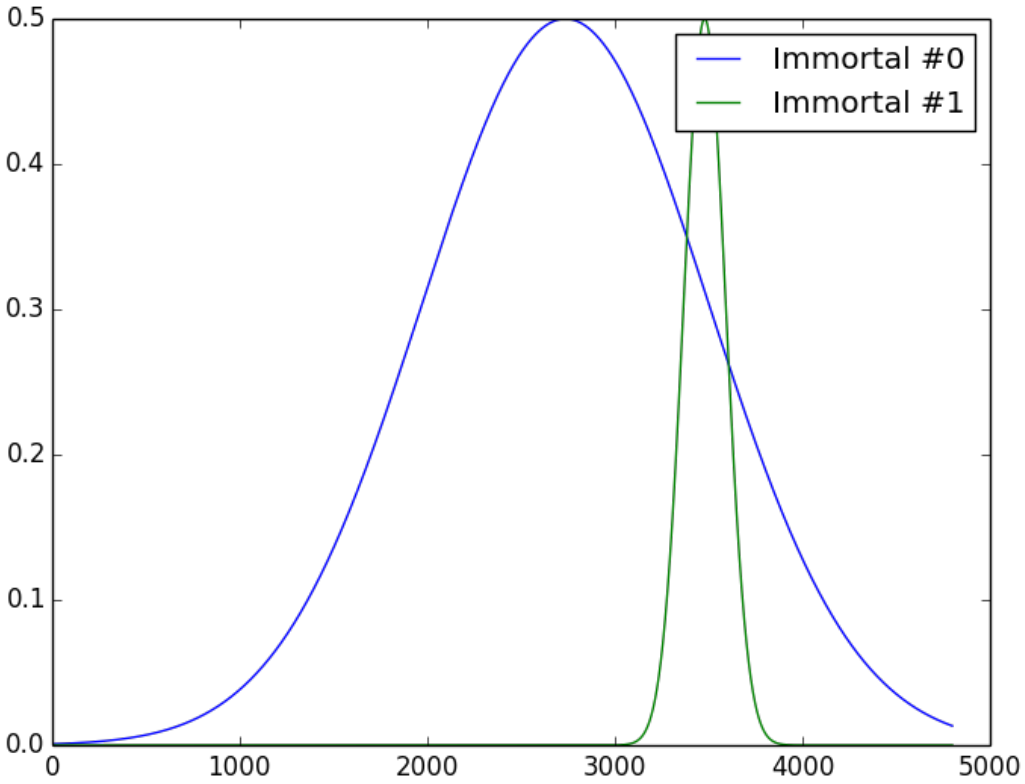

4.1 Autoclassificação

Após o treinamento, foi calculado o índice de "autoclassificação"que é a taxa de acerto do método ao classificar os mesmos *replays* utilizados no treinamento. Os resultados deste teste estão expostos na Tabela 3.

Tabela 3 – Resultado da autoclassificação

Build order	Acertos	Total	Taxa de acerto
Adept Glaives	6	6	1.0
Adept Stargate	7	14	0.5
Adept Immortal	11	13	0.85
Stalker Immortal	3	3	1.0
Adept Prism DT	5	5	1.0
Stalker Disruptor	2	5	0.4
Blink Stalker	6	8	0.75

Estes resultados apontam para um erro de classificação alto para as *build orders* "Adept Stargate", que engloba 3 *build orders* diferentes, sob uma sequência de ações iniciais

semelhantes. A alta taxa de erro é justificada pela frequência de ocorrência das últimas ações com 3 *branches* possíveis, implica na redução do valor da função distribuição de probabilidade do par ação-repetição. A taxa de erro de "Stalker Disruptor"é justificada pelo fato das duas *build orders* "Stalker Disruptor"e "Stalker Immortal"serem extremamente semelhantes. A diferença das duas está no final, ao redor dos 6 minutos de partida, onde as ações são truncadas. A truncagem das ações causa com que a taxa de erro seja maior do que esperada.

4.2 Validação cruzada

A fim de realizar a validação do resultado, utilizou-se um *dataset* individual de *replays* que não foram utilizados no treinamento para validar os resultados do método. O número de *replays* foi limitado pela capacidade manual de classificação. Neste dataset, um número variável de *replays* foi utilizado.

Tabela 4 – Resultado da validação cruzada

Build order	Acertos	Total	Taxa de acerto
Adept Glaives	3	3	1.0
Adept Stargate	3	4	0.75
Adept Immortal	10	11	0.90
Stalker Immortal	6	7	0.85
Adept Prism DT	1	1	1.0
Stalker Disruptor	14	16	0.875
Blink Stalker	10	12	0.83

4.3 Teste de ruído

Para testar a robustez do método sob condições de informações incompletas, como seria necessário caso uma inteligência artificial (AI) estivesse testando as possibilidades de ações de um jogador humano.

Neste teste, foi removido de forma aleatória um percentual de ações de cada *build order* do *dataset* de validação. Para que o teste seja replicável, utilizou-se o nome do replay (conforme indicado no índice dos *replays* do *dataset* de treinamento) como *seed* para a geração da sequência de exclusão das ações. Isto garante que independente de onde e quem execute o algoritmo, o resultado será o mesmo.

Tabela 5 – Resultado da validação cruzada com adição de ruído

Build order	2%	5%	10%	20%	30%	50%	70%	80%
Stalker Immortal	0.86	0.57	0.43	0.14	0.29	0.14	0.29	0.43
Adept Glaives	1.00	1.00	0.33	0.00	0.00	0.00	0.00	0.00
Adept Stargate	0.75	0.75	0.50	0.25	0.50	0.00	0.00	0.00
Stalker Disruptor	0.88	0.69	0.38	0.06	0.00	0.00	0.00	0.00
Blink Stalker	0.83	0.67	0.75	0.50	0.42	0.33	0.25	0.17
Adept Immortal	0.91	0.73	0.73	0.64	0.55	0.27	0.00	0.00
Adept Prism DT	1.00	1.00	0.00	1.00	1.00	0.00	0.00	0.00

No teste de ruído é observável que algumas das *build orders* onde o classificador obteve o melhor desempenho, como é o caso da "Adept Prism DT", o classificador também foi capaz de suportar maior nível de ruído. Isto se deve provavelmente ao fato desta *build order* em especial, ser bastante diferente das demais.

4.4 Comparação

Para realizar a comparação, foram classificados vários *replays* de vários campeonatos do ano de 2016 e construídos pares de *build orders*, onde foi calculada a taxa de vitória de uma em relação à outra. A Tabela 6 apresenta os resultados da taxa de vitória cruzada, isto é, dada uma *build order* (linha) qual a taxa de vitória desta contra outra *build order* qualquer (coluna). Itens onde não houveram partidas encontradas, a taxa está identificada com o símbolo '-'.

Tabela 6 – Resultado da comparação de taxa de vitória

	Adept Glaives	Adept Immortal	Adept Prism DT	Adept Stargate	Blink Stalker	Stalker Disruptor	Stalker Immortal
Adept Glaives	-	1.00	-	-	-	-	-
Adept Immortal	0.00	0.50	-	1.00	0.50	0.89	0.62
Adept Prism DT	-	-	-	-	1.00	-	-
Adept Stargate	-	0.00	-	-	-	-	-
Blink Stalker	-	0.50	0.00	-	0.50	0.00	0.83
Stalker Disruptor	-	0.11	-	-	1.00	0.50	0.33
Stalker Immortal	-	0.38	-	-	0.17	0.67	0.50

A partir dos dados da Tabela 6, uma inteligência artificial que esteja jogando contra um oponente que parece estar executando a *build order* "Stalker Disruptor", a melhor escolha que esta AI poderia tomar é de executar "Adept Immortal", pois maximiza taxa de vitória.

A vitória ou derrota de um jogador pode não ser diretamente relacionada à *build order*, mas sim devido a outras decisões ao longo da partida, em especial quando a partida se extende além dos 10 minutos iniciais. Dessa forma, uma métrica para estes casos seria a taxa de sobrevivência após os 10 minutos de jogo, isto, a frequência com que uma *build order* garante que o jogador **não perca** antes dos 10 minutos. É importante observar que

o critério é não perder, ou seja, não se tem interesse na vitória ou derrota do jogador após os 10 minutos.

Tabela 7 – Resultado da comparação de taxa de subrevivência após os 10 minutos de jogo

	Adept Glaives	Adept Immortal	Adept Prism DT	Adept Stargate	Blink Stalker	Stalker Disruptor	Stalker Immortal
Adept Glaives	-	0.00	-	-	-	-	-
Adept Immortal	0.00	0.33	-	0.50	0.50	0.44	0.62
Adept Prism DT	-	-	-	-	0.00	-	-
Adept Stargate	-	0.50	-	-	-	-	-
Blink Stalker	-	0.50	0.00	-	0.25	1.00	0.33
Stalker Disruptor	-	0.44	-	-	1.00	0.00	0.33
Stalker Immortal	-	0.62	-	-	0.33	0.33	0.62

Na Tabela 7, é possível tomar decisões de qual *build order* garante a maior chance de sobreviver até estágios finais de uma partida. Por exemplo, dado que um oponente esteja executando "Stalker Disruptor"(coluna), a que melhor garante a sobrevivência até os 10 minutos de jogo é "Adept Immortal"(linha).

5 Conclusões

Conforme visto no teste de autoclassificação, o método possui dificuldade em classificar *build orders* muito genéricas onde há alta possibilidade de variação, conforme é o caso da *build order* "Adept Stargate". No teste de validação cruzada, o método foi capaz de conseguir uma taxa de aproximadamente 85% de acerto, chegando a 100% de acertos em alguns casos específicos, embora com poucas amostras.

Build orders que possuem várias ações opcionais ou alternativas, como é o caso de "Adept Stargate"onde próximo dos 5 minutos de jogo pode ser escolhido entre 3 opções diferentes. *Build orders* com esta caraterística apresentaram problemas de classificação devido ao fator A presente na função distribuição de probabilidade (Equação 3.4) pois a frequência de ocorrência das ações é menor. Se uma ação é opcional, sua frequência é menor do que 1.0, implicando com que o valor máximo da função distribuição de probabilidade, A, seja menor. A vantagem desde efeito é que ele permite que seja possível classificar *build orders* em vários níveis de especificidade. É possível ter uma *build order* bastante genérica que engloba uma raíz comum à várias outras ou uma *build order* bastante específica. A utilização de uma *build order* genérica permite que seja viável classificar em função de "troncos"comuns à várias estratégias, que permite que o algoritmo seja reforçado para novas *build orders* desconhecidas.

Build orders semelhantes com pequena divergência ao final (próximo ao 6 minutos) apresentaram erros de classificação significantes, em especial "Stalker Disruptor"no teste de autoclassificação. Acredita-se que a causa desses erros é devido à grande variabilidade ao final da execução destas ações, inclusive alguns casos em que as ações passavam do limite de 6 minutos.

No teste de qualidade da classificação para simular condições de classificação em tempo real, foi adicionado de ruído (remoção de ações) para simular condizente com uma em que o jogo estivesse sendo jogado em tempo real, como seria caso um algoritmo de inteligência artificial estivesse precisando inferir informações sobre a estratégica de um jogador. Nestes testes, *build orders* mais distintas e características como "Adept Prism DT", onde a classificação mesmo com 30% conseguiu manter a taxa de acerto. Demais *build orders* perderam significantemente a taxa de acerto com o aumento de ruído.

As Tabelas 6 e 7 apresentaram as taxas de vitória e de sobrevivência de cada *build order*. A taxa de vitória é uma métrica importante para partidas mais curtas, pois com o decorrer do tempo, o efeito da *build order* inicial perde importância. A taxa de vitória permite com que seja possível escolher a combinação com a melhor possibilidade de vitória dada a *build order* do oponente. A taxa de sobrevivência indica a possibilidade de um

jogador sobrevier por no mínimo 10 minutos de jogo, dada uma estratégia do oponente, permitindo que seja possível selecionar a *build order* que permite com que o jogo seja levado até os estágios mais avançados e finais da partida. Esta decisão pode ser útil caso o jogador possua algum plano que só pode ser executado com eficácia nos instantes mais tardios de uma partida.

6 Propostas de Trabalhos Futuros

O método de classificação poderia utilizar um mecanismo de ações-chave para reforço dos resultados. Uma ação-chave é uma ação que é uma única ação capaz de definir com bastante exatidão. Caso não consiga reduzir as possibilidades para uma única, ao menos consegue reduzir significantemente a lista de possíveis resultados.

O método proposto é completamente *offline*. Isto é, não é capaz de classificar as ações dos jogadores conforme estas vão acontecendo. Uma sugestão é que o algoritmo seja implementado utilizando um método *online*, isto é, possa classificar e obter resultados da classificação ao decorrer da partida. Também é possível a implementação direto no jogo através da linguagem de programação Galaxy, integrada ao jogo e utilizada para desenvolvimento de inteligências artificiais e *scripts* customizados para mapas.

O desenvolvimento de um banco de dados de arquivos de *replays* utilizando métodos de *crowd sourcing* é capaz de coletar quantidades enormes de dados que podem ser utilizados para expandir o universo restrito de *build orders* utilizadas neste trabalho. Para auxiliar o trabalho, um método heurístico de segmentação e uma realimentação do classificador é possível para que o resultado seja refinado ao longo do processo.

Referências Bibliográficas

Blizzard Entertainment, Inc. *s2protocol*. 2013. Disponível em: <https://github.com/Blizzard/s2protocol>.

HORN, C. R. J. R. A. *Matrix Analysis*. 1st. ed. CUP, 1990. ISBN 0521305861, 0521386322. Disponível em: <http://gen.lib.rus.ec/book/index.php?md5=03e9a9ebb67da1d5fa059774b3a12c4b>.

SYNNAEVE, G.; BESSIERE, P. A bayesian model for opening prediction in rts games with application to starcraft. In: IEEE. *2011 IEEE Conference on Computational Intelligence and Games (CIG'11)*. [S.l.], 2011. p. 281–288.

SYNNAEVE, G.; BESSIERE, P. A bayesian model for plan recognition in rts games applied to starcraft. *arXiv preprint arXiv:1111.3735*, 2011.

WEBER, B. G.; MATEAS, M. A data mining approach to strategy prediction. In: IEEE. *2009 IEEE Symposium on Computational Intelligence and Games*. [S.l.], 2009. p. 140–147.

Glossário

A | B | E | G | M | P | R | S | T | U

A

Adept

unidade básica de exército da raça Protoss. 27, 42, *veja* Protoss

arvore tecnológica

árvore de dependências que define pré-requisitos tecnológicos (melhoramentos ou estruturas) para aquisição de uma nova tecnologia.

B

build order

conjunto de ações ordenadas que formam a estratégia inicial de um jogador.

E

estrutura

uma construção (semelhante à um edifício) construído dentro do jogo com objetivo de treinar unidades, melhoramentos ou liberações da arvore tecnológica.

G

Gateway

estrutura de treinamento de unidades básicas terrestes da raça Protoss. *veja* Protoss

Glaives

apelido para o melhoramento "Resonating Glaives". Aumenta a velocidade de ataque da unidade Adept aumentando significantemente seu poder bélico. *veja* Adept

gás

recurso utilizado para unidades, estruturas ou melhoramentos mais avançados tecnologicamente.

M

melhoramento

melhoramento de atributos de alguma unidade ou estrutura. Exemplo: aumento de velocidade de deslocamento, aumento de dano por ataque, aumento de velocidade de ataque. 17, 27, 30, 42, 43, *veja* estrutura & unidade

minério

recurso mais básico e abundante do jogo. Requisito para todas unidades, estruturas ou melhoramentos.

P

Protoss

uma das 3 raças disponíveis no jogo.

R

raça

facção, espécie das unidades do jogador. Existem 3 raças disponíveis: Terran, Zerg e Protoss. Cada raça possuí mecânicas, unidades, estruturas e melhoramentos completamente diferentes. 10–12, 24, 32, 42, 43, *veja* Protoss

recurso

análogo à dinheiro ou matéria prima. Recursos básicos necessários para construir estruturas ou treinar unidades.

repetição

execução de uma ação múltiplas vezes.

replay

arquivo binário que contém todas ações realizadas durante um jogo, contém informações o suficiente para que seja possível reexecutar uma simulação do jogo caso seja necessário assistir o jogo. Também incluí algumas informações pré-processadas para uso de ferramentas externas..

Robo

apelido para "Robotics Bay", estrutura de treinamento de unidades terrestres avançadas da raça Protoss. *veja* Protoss

S

Stargate

estrutura de treinamento de unidades aéreas da raça Protoss. *veja* Protoss

suprimento

grandeza que impõe um limite de unidades que um jogador pode construir. Após atingir o limite, novas unidades só podem ser treinadas com a perda de outras.

T

trabalhador

unidade básica cuja função é extrair recursos e construir estruturas.

treinar

ato de criar uma unidade durante o jogo. Requer que os pré-requisitos para cada unidade sejam fornecidos e que haja recursos o suficiente (minérios e gás).

U

unidade

soldado, personagem do jogo com objetivo militar.

ANEXO A – Lista de nomes de ações utilizadas

- Adept
- AdeptPiercingAttack
- Archon
- Assimilator
- BlinkTech
- Carrier
- CarrierLaunchSpeedUpgrade
- Charge
- Colossus
- CyberneticsCore
- DarkShrine
- DarkTemplar
- Disruptor
- ExtendedThermalLance
- FleetBeacon
- Forge
- Gateway
- GraviticDrive
- HighTemplar
- Immortal
- Mothership
- MothershipCore
- Nexus
- Observer
- ObserverGraviticBooster
- Oracle
- Phoenix
- PhoenixRangeUpgrade
- PhotonCannon
- ProtossAirArmorsLevel1
- ProtossAirArmorsLevel2
- ProtossAirArmorsLevel3
- ProtossAirWeaponsLevel1
- ProtossAirWeaponsLevel2
- ProtossAirWeaponsLevel3
- ProtossGroundArmorsLevel1
- ProtossGroundArmorsLevel2
- ProtossGroundArmorsLevel3
- ProtossGroundWeaponsLevel1
- ProtossGroundWeaponsLevel2
- ProtossGroundWeaponsLevel3
- ProtossShieldsLevel1
- ProtossShieldsLevel2
- ProtossShieldsLevel3
- PsiStormTech

- RoboticsBay
- RoboticsFacility
- Sentry
- Stalker
- Stargate
- Tempest
- TemplarArchive
- TwilightCouncil
- VoidRay
- WarpGate
- WarpGateResearch
- WarpPrism
- Zealot